

Afet Tweetlerinin Tespiti

Zeynep KİCIKOĞLU

**İstanbul Medeniyet Üniversitesi, Mühendislik ve Doğa Bilimleri
Fakültesi, Bilgisayar Mühendisliği Bölümü**

Özet

Arka Plan: Doğal afetlerle ilgili tweetlerin hızlı ve doğru bir şekilde tespit edilmesi, acil durum müdahalesi ve kaynak tahsisini önemli ölçüde artırabilir. Geleneksel manuel yöntemler zaman alıcı ve verimsizdir. Bu çalışma, tweetleri afetle ilgili veya normal olarak sınıflandırmak için doğal dil işleme (NLP) ve makine öğrenimi kullanarak otomatik bir model geliştirmeyi amaçlamaktadır.

Yöntemler: Kaggle'dan alınan ve "Afet" veya "Normal" olarak etiketlenmiş tweetleri içeren bir veri seti kullandık. Veri seti, durak kelimeler ve noktalama işaretlerinin kaldırılması ve lemmatizasyon işlemleri ile ön işlemden geçirildi. Tekli n-gramlardan üçlü n-gramlara kadar Term Frequency-Inverse Document Frequency (TF-IDF) kullanılarak metin özellikleri çıkarıldı. Çoklu Naive Bayes ve Pasif Agresif Sınıflandırıcı dahil olmak üzere çeşitli sınıflandırıcılar eğitildi ve performansları çapraz doğrulama ile değerlendirildi. Ayrıca, model performansını iyileştirmek için hiperparametre optimizasyonu amacıyla Grid Search yöntemi kullanıldı.

Sonuçlar: TF-IDF bigramları ile Çoklu Naive Bayes modeli %79.52 doğruluk elde etti ve Pasif Agresif Sınıflandırıcı %79.37 doğruluk sağladı. Hiperparametre optimizasyonu için Grid Search kullanılarak en iyi modelin performansı daha da artırıldı, bu da metin sınıflandırma görevlerinde hiperparametre optimizasyonunun önemini vurguladı. Geliştirilen model, doğal afetlerle ilgili tweetleri otomatik olarak sınıflandırmak için güvenilir bir yöntem sunmakta ve manuel yöntemlere kıyasla önemli zaman tasarrufu sağlamaktadır. Bu yaklaşım, acil durumlar sırasında durumsal farkındalığı ve karar alma süreçlerini geliştirme potansiyeli ile gerçek zamanlı metin sınıflandırması gerektiren çeşitli alanlara uyarlanabilir.

Anahtar Kelimeler: Doğal afet tweet sınıflandırması, NLP, TF-IDF, Çoklu Naive Bayes, Pasif Agresif Sınıflandırıcı, Grid Search, Makine Öğrenimi

1. İlgili Çalışmalar

Giriş

Doğal afetlerle ilgili tweetlerin sınıflandırılması, afet yönetimi ve acil durum müdahalesi açısından büyük önem taşımaktadır. Bu alandaki çalışmalar, sosyal medya verilerinin büyük hacmini hızlı ve etkili bir şekilde analiz ederek, afetler hakkında gerçek zamanlı bilgi sağlamayı amaçlamaktadır. Bu bölümde, doğal afet tweet sınıflandırması üzerine yapılan önceki çalışmaları inceleyerek, mevcut yaklaşımlar ve bu çalışmanın literatüre nasıl katkıda bulunduğu ele alınmıştır.

Doğal Dil İşleme ve Makine Öğrenimi Uygulamaları

Sosyal medya verilerinin analizi, özellikle Twitter gibi platformlarda, doğal dil işleme (NLP) ve makine öğrenimi tekniklerinin yaygın olarak kullanıldığı bir alandır. Afet tweetlerini sınıflandırmak için kullanılan başlıca yöntemler şunlardır:

1. Bag of Words (BoW) ve TF-IDF:

- Bu yöntemler, metin verilerini sayısal vektörlere dönüştürerek sınıflandırma modelleri için uygun hale getirir. BoW, her kelimenin frekansını hesaplar ve belge matrisi oluşturur. TF-IDF ise, kelimelerin belge içerisindeki önemini belirleyerek daha hassas bir özellik çıkarımı sağlar. Örneğin, Sakaki et al. (2010) Twitter verilerini kullanarak deprem tespiti yapmış ve TF-IDF ile yüksek başarı elde etmiştir.

2. Kelime Gömme Teknikleri:

- Word2Vec ve GloVe gibi kelime gömme yöntemleri, kelimeler arasındaki bağlamsal ilişkileri öğrenerek daha zengin metin temsilleri sağlar. Bu teknikler, metin sınıflandırma görevlerinde daha yüksek doğruluk oranları elde etmeye yardımcı olur.

3. Makine Öğrenimi Modelleri:

- Naive Bayes, Destek Vektör Makineleri (SVM), Lojistik Regresyon ve Derin Öğrenme modelleri gibi çeşitli makine öğrenimi algoritmaları, afet tweetlerinin sınıflandırılmasında kullanılmıştır. Özellikle, Pasif Agresif Sınıflandırıcı ve Naive Bayes modelleri, hız ve doğruluk açısından avantaj sağlamaktadır.

Hiperparametre Optimizasyonu

Makine öğrenimi modellerinin performansını artırmak için hiperparametre optimizasyonu önemli bir adımdır. Grid Search yöntemi, modelin en iyi performansı göstermesi için optimal parametreleri belirlemeye yardımcı olur. Örneğin, Grid Search kullanarak en iyi n-gram aralığı ve maksimum belge frekansı gibi parametrelerin optimize edilmesi, sınıflandırma doğruluğunu artırabilir.

Bu Çalışmanın Katkısı

Bu çalışma, doğal afetlerle ilgili tweetlerin sınıflandırılması üzerine yapılan çalışmalara birkaç önemli katkı sağlamaktadır:

1. N-gram Analizi:

- Çalışmamız, tekli, ikili ve üçlü n-gramlar kullanarak TF-IDF özellik çıkarımını karşılaştırmış ve sınıflandırma performansı üzerindeki etkilerini analiz etmiştir. Bu, afet tweet sınıflandırmasında n-gram seçiminin önemini vurgulamaktadır.

2. Farklı Modellerin Kıyaslanması:

- Çoklu Naive Bayes ve Pasif Agresif Sınıflandırıcı gibi çeşitli makine öğrenimi modelleri kullanılarak, bu modellerin performansları karşılaştırılmıştır. Bu, farklı model ve hiperparametre kombinasyonlarının etkinliğini göstermektedir.

3. Hiperparametre Optimizasyonu:

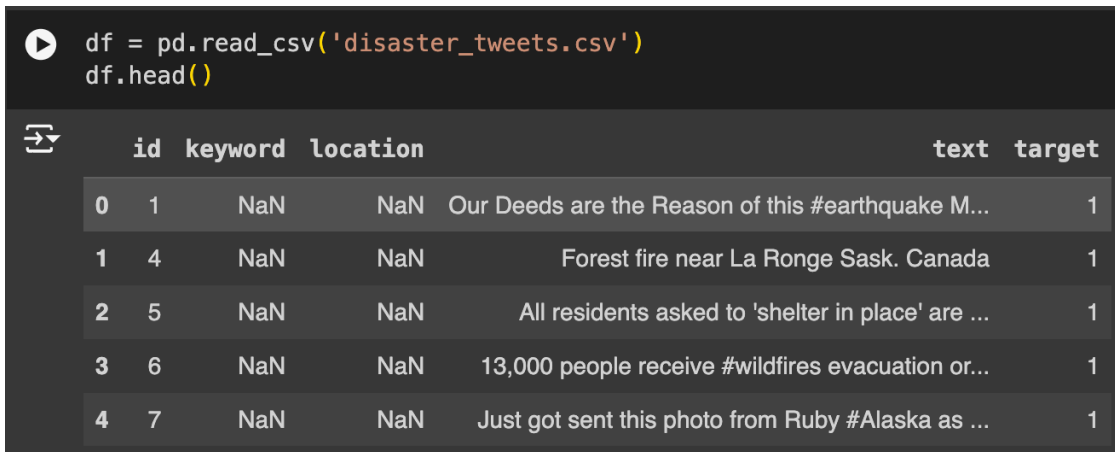
- Grid Search yöntemi ile en iyi hiperparametrelerin belirlenmesi, modelin doğruluk oranını artırmış ve sınıflandırma görevlerinde hiperparametre optimizasyonunun önemini ortaya koymuştur.

Bu çalışma, doğal afetlerle ilgili tweetlerin otomatik olarak sınıflandırılmasında NLP ve makine öğrenimi tekniklerinin etkin kullanımını göstermekte ve literatüre önemli katkılar sunmaktadır. Bu yaklaşım, afet yönetimi ve acil durum müdahalesi süreçlerinde karar verme sürecini iyileştirme potansiyeline sahiptir.

2. Veri Seti ve Ön İşleme

2.1. Veri Setinin Yüklenmesi ve İncelenmesi

Veri seti, Kaggle'dan yüklenmiştir ve pandas kütüphanesi kullanılarak incelenmiştir.



```
df = pd.read_csv('disaster_tweets.csv')
df.head()
```

	id	keyword	location	text	target
0	1	NaN	NaN	Our Deeds are the Reason of this #earthquake M...	1
1	4	NaN	NaN	Forest fire near La Ronge Sask. Canada	1
2	5	NaN	NaN	All residents asked to 'shelter in place' are ...	1
3	6	NaN	NaN	13,000 people receive #wildfires evacuation or...	1
4	7	NaN	NaN	Just got sent this photo from Ruby #Alaska as ...	1

Görsel 1. Veri Setinin Çıktı Görüntüsü


2.2. Veri Setinin Görselleştirilmesi

Tweetlerin hedef sınıf (afetle ilgili = 1 veya afetle ilgili değil = 0) dağılımı bir çubuk grafikte görselleştirilmiştir.



Görsel 2. Verinin Dengeli Olup Olmamasının Kontrolü

Tweetlerin uzunlukları da hesaplanıp yeni bir değişken olarak veriye eklenip uzunluklarının görselleştirilmesi için histogram grafiğinden yararlanılmıştır.



Görsel 3. Tweetlerin Uzunluğunun Görselleştirilmesi

2.3. Veri Temizleme


İngilizce dilinde bir dizi durak kelimesi ve noktalama işareti oluşturulur. Bir fonksiyon tanımlanır. Bu fonksiyon temizlenecek metin verilerini alır. Metin küçük harfe dönüştürülür ve kelimelere ayrılır. Her kelime kontrol edilir: Eğer kelime durdurma kelimelerinden veya noktalama işaretlerinden biri değilse, kelimenin köküne lemmatize edilir. Temizlenen metin, yalnızca alfabenin karakterlerini içerecek şekilde düzenlenir. Son olarak, temizlenmiş metin döndürülür.

text	cleaned_tweets
Our Deeds are the Reason of this #earthquake M...	deed reason earthquake may allah forgive u
Forest fire near La Ronge Sask. Canada	forest fire near la ronge sask canada
All residents asked to 'shelter in place' are ...	resident asked shelter place notified offic...
13,000 people receive #wildfires evacuation or...	people receive wildfire evacuation or...
Just got sent this photo from Ruby #Alaska as ...	got sent photo ruby alaska smoke wildfire ...

Görsel 4-5. Eski Metin ve Temizlenmiş Metin

2.4. WordCloud Görselleştirmesi

Temizlenmiş tweetlerden WordCloud (Kelime Bulutu) oluşturulmuştur. Kelime bulutu, metin verisinin içinde en sık kullanılan kelimelerin görsel bir temsilini sağlar. Aşağıda felaket içeren tweetlerin içeriğine dayalı olarak oluşturulmuş bir kelime bulutu görülmektedir.



Görsel 6. Afet Tweetlerinin Kelimw Bulutu

3. Model Eğitimi ve Değerlendirilmesi

3.1. Veri Setinin eğitim ve Test Setlerine bölünmesi

Veri seti, eğitim ve test setlerine bölünmüştür. İlk olarak, veri setindeki hedef değişken (target) ile özellik değişkenlerinin (features) ayrılması sağlanır. Daha sonra, veri seti eğitim ve test alt kümelerine ayrılır. Bu işlem, modelin eğitimi sırasında kullanılacak veriyi eğitim ve test olarak bölerek, modelin performansını değerlendirmek için ayrı bir veri seti elde edilmesini sağlar.

3.2. TF-IDF Vektörizasyonu

TF-IDF (Term Frequency-Inverse Document Frequency) vektörizer kullanılarak tweetler vektörize edilmiştir. Metin verileri sayısal vektörlere dönüştürülür. Bu vektörleştirici, metin belgelerindeki kelimelerin frekanslarını temel alarak her bir kelimenin önemini ölçer. Özellikle, bu kod parçasında, TF-IDF vektörleştiricisi, İngilizce durma kelimelerini ve belirli bir sıklığın üzerinde bulunan kelimeleri dikkate almaz ve kelime çiftlerini (bi-gram/tri-gram) içerir.

3.3. Multinomial Naive Bayes Modeli

Multinomial Naive Bayes algoritması ile eğitilmiş bir metin sınıflandırma modelinin performansı değerlendirilir. Model, TF-IDF (Term Frequency-Inverse Document Frequency) vektörleştirme yöntemi kullanılarak metin verilerini sayısal özelliklere dönüştürmektedir. Model, bi-gramlar kullanarak metinlerin içerdiği kelime çiftlerini dikkate almaktadır.

Eğitim ve Test Verisi

Eğitim verisi, veri setinin %80'ini oluştururken, test verisi %20'sini oluşturmaktadır. Veri seti, dengeli bir şekilde sınıflandırılmıştır, yani hem felaket içeren tweetler hem de normal tweetler eğitim ve test veri setlerinde adil bir şekilde temsil edilmektedir.

Sonuçlar

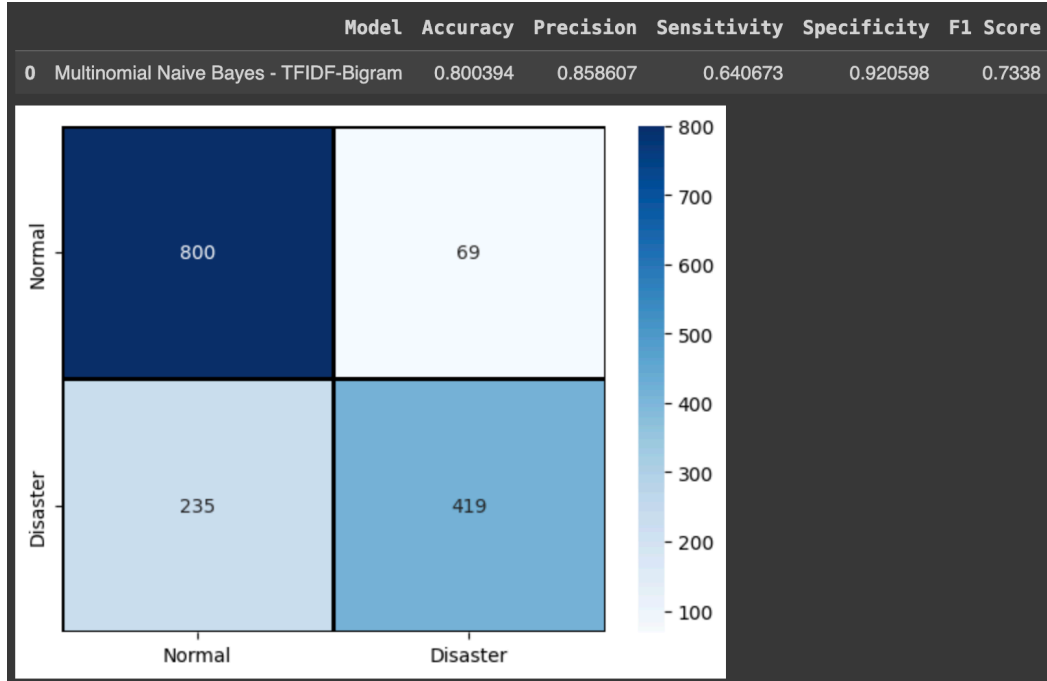
Modelin performansı, doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), özgüllük (specificity) ve F1 skoru gibi metriklerle değerlendirilmiştir.

Doğruluk (Accuracy): Modelin doğru sınıflandırma oranıdır. Yüksek doğruluk değeri, modelin ne kadar etkili olduğunu gösterir.

Hassasiyet (Precision): Pozitif olarak sınıflandırılan örneklerin ne kadarının gerçekten pozitif olduğunu gösterir. Yani, yanlış pozitif sınıflandırmaların oranını belirler.

Duyarlılık (Recall): Gerçekten pozitif olan örneklerin ne kadarının doğru bir şekilde pozitif olarak sınıflandırıldığını gösterir. Yani, yanlış negatif sınıflandırmaların oranını belirler. Özgüllük (Specificity): Gerçekten negatif olan örneklerin ne kadarının doğru bir şekilde negatif olarak sınıflandırıldığını gösterir.

F1 Skoru: Hassasiyet ve duyarlılığın harmonik ortalamasıdır. Dengeli bir performans ölçüsü sağlar.

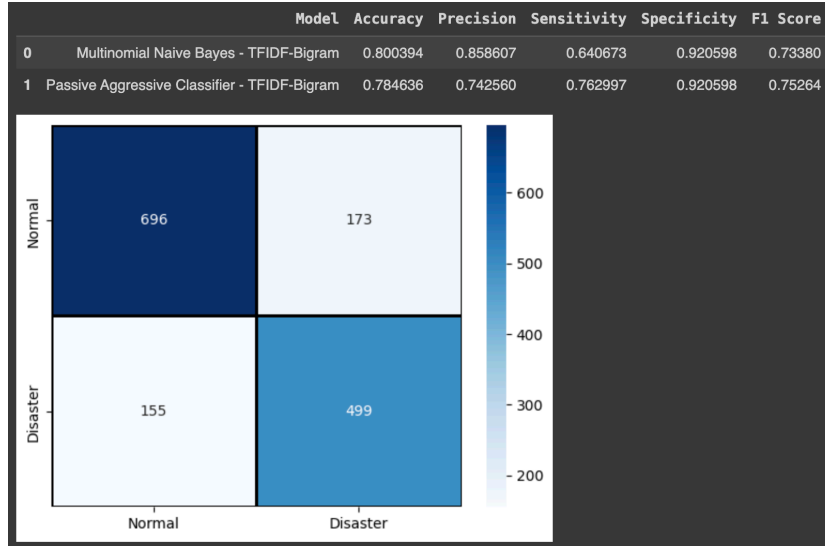


Görsel 7. Multinomial Naive Bayes TF- IDF-Bigram Doğruluğu

3.4. Passive Aggressive Classifier Modeli

Passive Aggressive Classifier algoritması ile eğitilmiş bir metin sınıflandırma modelinin performansını değerlendirmektedir. Model, TF-IDF (Term Frequency-Inverse Document Frequency) vektörleştirme yöntemi kullanılarak metin verilerini sayısal özelliklere dönüştürmektedir. Model, bi-gramlar kullanarak metinlerin içerdiği kelime çiftlerini dikkate almaktadır.

Sonuçlar




Görsel 8. Passive Aggressive Classifier TF- IDF-Bigram Doğruluğu

3. 5. TF-IDF Trigram Vektörizasyonu ve Model Eğitimi

3. 5.1. Multinomial Naive Bayes

TF-IDF vektörizasyonu kullanılarak tri-gramlarla eğitilen Multinomial Naive Bayes algoritmasının performansını değerlendirmektedir.

Sonuçlar

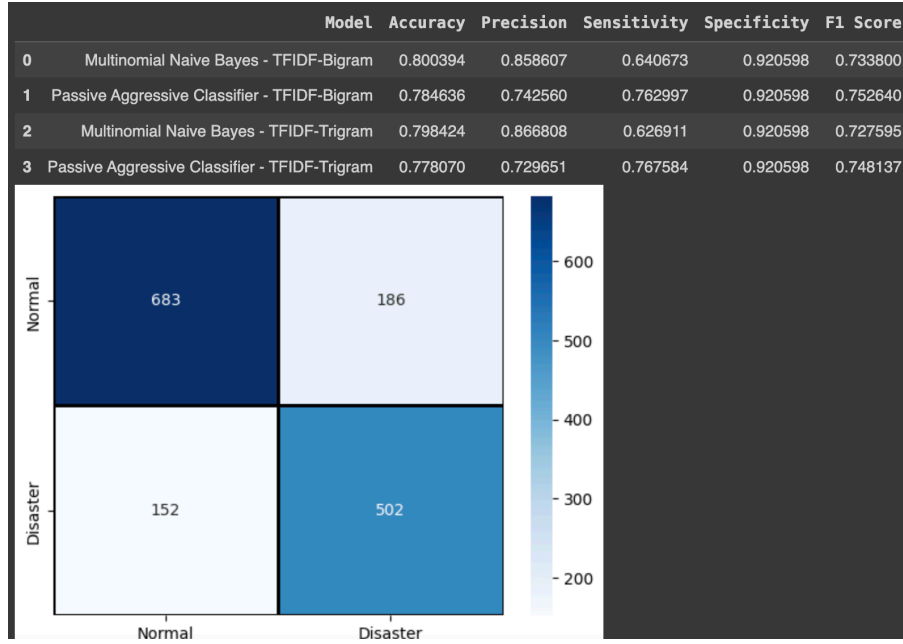


Görsel 9. Multinomial Naive Bayes TF- IDF-Trigram Doğruluğu

3.5.2. Passive Aggressive Classifier

TF-IDF vektörizasyonu kullanılarak tri-gramlarla eğitilen Passive Aggressive Classifier algoritmasının performansını değerlendirmektedir.

Sonuçlar



Görsel 10. Passive Aggressive Classifier TF- IDF-Trigram Doğruluğu

4. Test Edilmesi ve Sonuçlar

Modelin tahmin sonuçlarına bakıldığında, afet durumlarını içeren tweetleri başarıyla tespit ettiği görülmektedir. "Fire", "earthquake", "car accident", "tornado warning" ve "tsunami warning" gibi afet durumlarını içeren tweetler doğru bir şekilde "Disaster Tweet" olarak sınıflandırılmıştır. Aynı şekilde, günlük olayları veya hava durumunu içeren tweetler de doğru bir şekilde "Normal Tweet" olarak sınıflandırılmıştır. Bu sonuçlar, modelin afet tweetlerini tanıma konusundaki yüksek performansını göstermektedir.

```
Text: There is a fire in the building, please evacuate immediately.
Class: Disaster Tweet

Text: I love sunny days, let's go for a picnic!
Class: Normal Tweet

Text: An earthquake hit the city, lots of buildings collapsed.
Class: Disaster Tweet

Text: The new restaurant in town is amazing, I highly recommend it!
Class: Normal Tweet

Text: Heavy rain is expected tomorrow, don't forget your umbrella.
Class: Disaster Tweet

Text: Just saw a car accident on the highway, traffic is blocked.
Class: Disaster Tweet

Text: The concert last night was fantastic, I had a great time!
Class: Normal Tweet

Text: Tornado warning issued for the area, take shelter immediately.
Class: Disaster Tweet

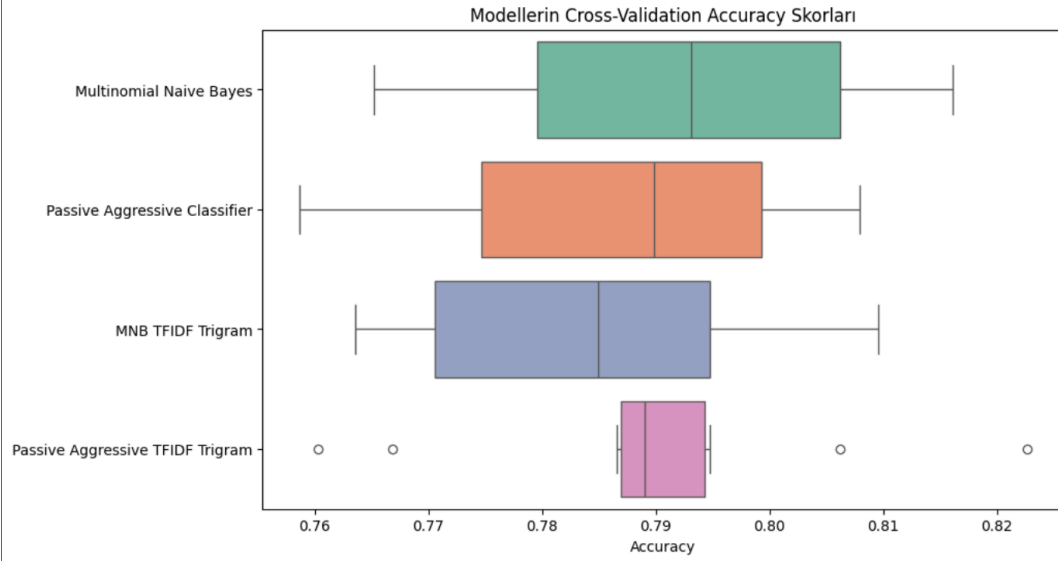
Text: I can't believe how cold it is today, winter is definitely here.
Class: Normal Tweet

Text: Received a tsunami warning on my phone, stay safe everyone.
Class: Disaster Tweet
```

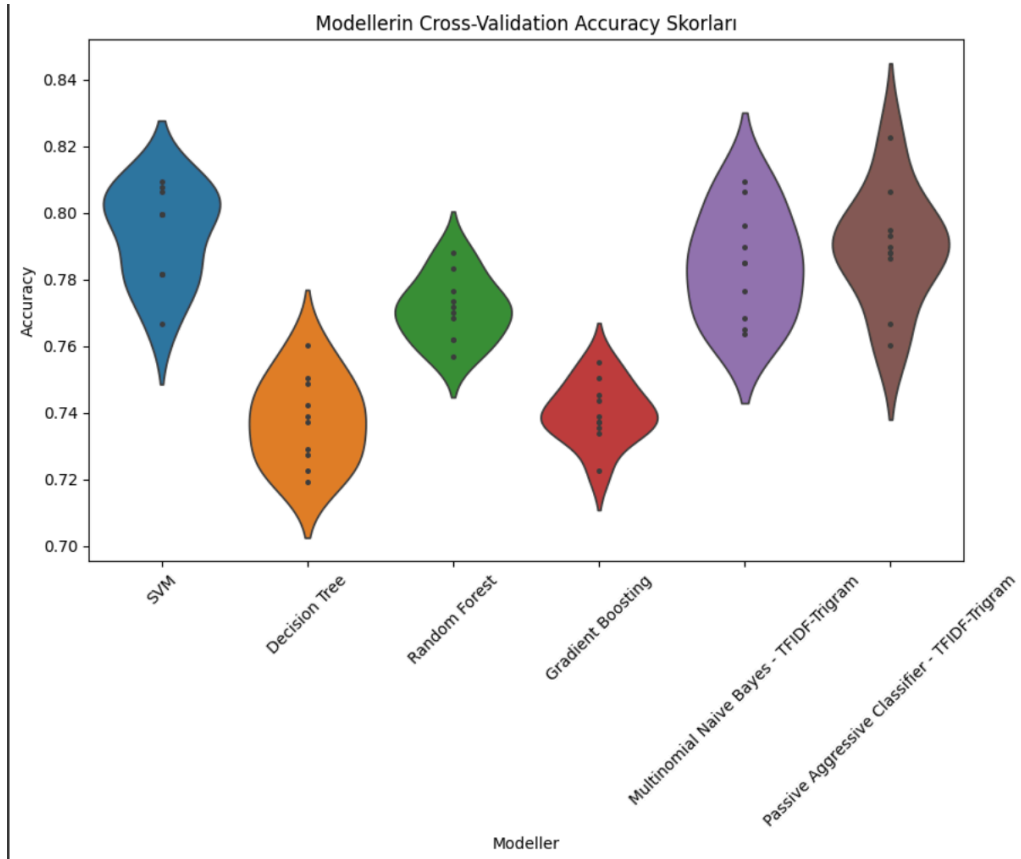
Görsel 11. Test Metinlerinin Tespit Sonuçları

5. Model Sonuçlarının Karşılaştırılması

Bu bölümde, çeşitli makine öğrenimi modellerinin cross-validation doğruluk skorlarının karşılaştırılması yapılmıştır. Modellerin performanslarını görselleştirmek ve analiz etmek amacıyla iki farklı grafik türü kullanılmıştır: boxplot ve violinplot. Bu grafikler, modellerin doğruluk skorlarının dağılımlarını ve merkezi eğilimlerini görsel olarak değerlendirmemize olanak tanımaktadır. Görsellerden de anlaşılacağı üzere en iyi sonucu veren model 0.800394 doğruluk skoru ile Multinomial Naive Bayes - TFIDF-Bigram olmuştur.



Görsel 12. Model Sonuçlarının Box-plot Yöntemiyle Karşılaştırılması



Görsel 13. Model Sonuçlarının Violinplot Yöntemiyle Karşılaştırılması